



Universidade de Brasília

Instituto de Ciências Exatas
Departamento de Ciência da Computação

Avaliação do uso de bibliotecas de aprendizagem de máquina para integração com simuladores de redes ópticas elásticas

Mikael Marques Mello

Monografia apresentada como requisito parcial
para conclusão do Bacharelado em Ciência da Computação

Orientador
Prof. Dr. André Costa Drummond

Brasília
2020



Avaliação do uso de bibliotecas de aprendizagem de máquina para integração com simuladores de redes ópticas elásticas

Monografia apresentada como requisito parcial
para conclusão do Bacharelado em Ciência da Computação

Prof. Dr. Guilherme Novaes Ramos Prof. Dr. Marcelo Antonio Marotta
CIC/UnB CIC/UnB

Prof. Dr. Marcelo Grandi Mandelli
Coordenador do Bacharelado em Ciência da Computação

Brasília, 5 de dezembro de 2020

Dedicatória

Dedico este trabalho à minha querida e amada noiva, Bruna Barros, por sempre estar ao meu lado e ter sido uma fonte interminável de amor e carinho desde que a conheci, incentivando-me a ser uma pessoa melhor. Os últimos dois anos e os próximos que virão não poderiam ser melhores.

Dedico à minha mãe, Rosicler, por sempre ter feito o possível e o impossível para que nada me faltasse, todas minhas conquistas só foram possíveis graças à sua dedicação em dar tudo pelos seus filhos.

Dedico ao meu pai, Gilvan, por sempre ter me fornecido os meios e oportunidades que eu precisava para alcançar meus objetivos, minhas conquistas também não seriam possíveis sem seu enorme apoio.

Agradecimentos

Primeiramente, gostaria de agradecer ao meu orientador, André Costa Drummond, por todo o auxílio e prestatividade desde o começo do ano pré-pandemia, e pela incrível didática de ensino que pude prestigiar ao assistir aulas da disciplina Redes de Computadores.

Gostaria de agradecer também aos professores e professoras Carla Castanho, Cláudia Nalon, Flávio Moura, Jorge Lucero e Marcus Lamar, pela maravilhosa qualidade de ensino em disciplinas que considero favoritas na minha graduação e felizmente tive o prazer de estudá-las com professores excelentes.

Agradeço imensamente à comunidade de Maratona de Programação, a qual acredito que minha participação foi crucial para o meu bom desempenho acadêmico e profissional. Agradecimentos especiais aos professores Guilherme Ramos, Edson Alves, Vinícius Borges e diversos outros, por todo o trabalho duro que mantém a comunidade local de programação competitiva viva e por se encarregarem de divulgarem e incentivarem esta prática pela UnB e em outras instituições de ensino, consideravelmente aumentando o nível da nossa universidade e da região. Além disso, agradeço ao Matheus Pimenta, por sua dedicação em incentivar tantos alunos, eu incluso, a participarem desta incrível experiência.

Por fim, agradeço também a diversos amigos que conheci durante esta caminhada e que sempre estiveram presentes para me ajudar com diversas questões acadêmicas e profissionais: Gabriel Nunes, Giovanni Guidini, Thiago Veras, Léo Moraes, Gabriel Levi, José Leite, Luis Felipe e Gabriel Taumaturgo.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES), por meio do Acesso ao Portal de Periódicos.

Resumo

Redes ópticas elásticas são consideradas por pesquisadores uma das melhores soluções atuais para lidar com o crescente tráfego global de dados, provendo diversos benefícios ao comparadas com alternativas tradicionais, sendo a principal vantagem a possibilidade de alocar recursos físicos de forma flexível que viabiliza estratégias mais eficientes de alocação. Pelo fato de estratégias tradicionais de alocação de recursos não serem apropriadas para o cenário flexível, diversos estudos para sobre novas estratégias de alocação têm sido desenvolvidos, e devido à complexidade de redes ópticas elásticas, tais estudos utilizam simulações para validar seus resultados. Recentemente, o uso de aprendizagem de máquina como ferramenta para o desenvolvimento de estratégias tem crescido, entretanto simuladores atuais da literatura não possuem suporte para uso de modelos de aprendizagem de máquina em suas implementações. Este trabalho apresenta uma análise qualitativa e quantitativa de bibliotecas de ML populares na literatura com o objetivo de definir direções e recomendações para futuras implementações, além de realizar uma contribuição ao Optical Network Simulator (ONS) com uma implementação inicial de funcionalidades para dar suporte ao uso de modelos de aprendizagem de máquina em simulações.

Palavras-chave: redes ópticas elásticas, aprendizagem de máquina

Abstract

Elastic optical networks are currently considered one of the best solutions to handle the increasing global data traffic, providing several benefits compared to traditional alternatives. The flexibility in resources allocation allows it to be done in an adaptable and efficient manner. However, traditional resource allocation algorithms are not appropriate for a flexible scenario, resulting in several studies with the goal to develop new allocation strategies, and because of the complexity of elastic optical networks, these studies often use simulations to validate their results. Recently, the use of machine learning as a tool for the development of strategies has been growing, although simulators currently found in the literature do not have support for using machine learning models in their implementations. This work presents a qualitative and quantitative analysis of popular ML libraries in the literature in order to define directions and recommendations for future implementations, besides contributing to the Optical Network Simulator (ONS) with an initial implementation of features that support the use of machine learning models in simulations.

Keywords: elastic optical networks, machine learning

Sumário

1	Introdução	1
1.1	Problema	3
1.2	Objetivos	4
1.3	Contribuições	4
1.4	Organização do trabalho	5
2	Fundamentação Teórica	6
2.1	Aprendizagem de Máquina	6
2.1.1	Aprendizado supervisionado	7
2.1.2	Aprendizado não-supervisionado	7
2.1.3	Aprendizado por reforço	7
2.2	Aprendizagem profunda	8
2.3	Simulações de EONs	8
2.4	Avaliações de Desempenho	8
2.4.1	Definição dos objetivos do estudo e do sistema	8
2.4.2	Listar serviços e resultados	8
2.4.3	Selecionar métricas	9
2.4.4	Listar parâmetros e fatores	9
2.4.5	Escolher a técnica de avaliação	9
2.4.6	Selecionar carga de trabalho	10
2.4.7	Desenho de experimentos	10
2.4.8	Apresentação de resultados	10
3	Análise de Bibliotecas	11
3.1	OpenCV	12
3.2	PyTorch	13
3.3	Scikit Learn	13
3.4	TensorFlow	13
3.5	Keras	14

3.6	TensorFlow Lite	14
3.7	ONNX Runtime	15
3.8	Deeplearning4j	16
3.9	MXNet	16
3.10	Outras tecnologias	17
4	Avaliação de Desempenho	18
4.1	Metodologia	18
4.2	Ambiente de Execução	20
4.3	Resultados	21
5	Propostas de Integração	24
5.1	Flexibilidade	24
5.2	Desempenho	25
5.3	Contribuições ao ONS	26
6	Conclusão	27
	Referências	29

Lista de Figuras

4.1	Tempo de execução de execuções sequenciais do modelo para cada combinação	21
-----	---	----

Lista de Tabelas

2.1 Critérios para a seleção de uma técnica de avaliação de desempenho [1]. . .	9
4.1 Estatísticas descritivas acerca do tempo de execução (microsegundos) do modelo em todas as combinações.	22

Lista de Abreviaturas e Siglas

API *Application Programming Interface.*

CEONS *Complex Elastic Optical Network Simulator.*

CUDA *Compute Unified Device Architecture.*

DL *Deep Learning.*

EON *Elastic Optical Networking.*

EONs *Elastic Optical Networks.*

ML *Machine Learning.*

N-WDM *Nyquist WDM.*

OAWG *Optical Arbitrary Waveform Generation.*

OFDM *Orthogonal Frequency Division Multiplexing.*

ONNX *Open Neural Network Exchange.*

ONS *Optical Network Simulator.*

RMLSA *Routing, Modulation Level and Spectrum Allocation.*

RSA *Routing and Spectrum Assignment.*

WDM *Wavelength-Division Multiplexing.*

Capítulo 1

Introdução

Historicamente, o tráfego de internet global cresce de forma exponencial, possuindo uma taxa composta de crescimento anual de 45% nos anos 2000 [2] e aproximadamente 30% nos anos 2010 [3, 4, 5, 6, 7, 8, 9, 10]. Uma fatia significativa deste crescimento anual se deve ao tráfego de dados em redes móveis, cujas taxas de crescimento anuais na última década tem variado entre 50% a 60% e são motivadas pelo crescente número assinaturas de *smartphones* e o volume de dados consumido por assinatura, este alavancado principalmente pelo crescente consumo de conteúdos de vídeo [11]. Além disso, circunstâncias especiais podem incentivar a população a aumentar ainda vez mais seu uso de internet: Em Abril de 2020, a empresa Akamai relatou um crescimento de 30% do tráfego global em apenas um mês, aproximadamente dez vezes a taxa de crescimento esperada, atribuindo o pico de crescimento às mudanças de estilo de vida causadas pela pandemia do COVID-19 [12].

A infraestrutura responsável por lidar com tamanho tráfego é composta por redes ópticas que têm sido tradicionalmente *rígidas* e *homogêneas*, isto é, redes baseadas em *Wavelength-Division Multiplexing* (WDM), ou multiplexação por divisão de comprimento de onda. Redes baseadas em WDM oferecem a possibilidade de estabelecer conexões com comprimentos de onda fixos e com uma taxa de *bits* fixa, em que os canais são modulados com um formato comum e espaçados por uma distância fixa de 50 GHz [13, 14]. O crescimento exponencial de demanda motivou a indústria a focar esforços em aumentar a capacidade destas redes, resultando na evolução das taxas de *bits* permitidas de inicialmente 10 Gb/s para 40 Gb/s e por fim 100 Gb/s [15]. Entretanto, este tipo de rede conta com alguns problemas:

- **Baixa adaptabilidade.** A flexibilidade destas redes é limitada pela configuração do *hardware*, tornando o processo de atualizar ou modificar a rede para se adaptar a mudanças de demanda ou de condições de rede desafiador [13].

- **Baixa eficiência espectral.** O desenho da rede deve garantir que o caminho óptico mais longo (pior caso) seja transmitido com qualidade suficiente. Como os comprimentos de onda são fixos e homogêneos, a maioria das conexões irá possuir comprimentos muito menores do que o pior caso, gerando um problema de ineficiência onde há faixas de comprimentos de onda não utilizadas [14, 15].
- **Limite de futuros avanços.** Com taxas de bits maiores que 100 Gb/s, melhorias na eficiência espectral ao aumentar o número de *bits* por símbolo se torna cada vez mais difícil devido ao limite de Shannon, além do fato de que aumentar a taxa para além de 100 Gb/s é um desafio por si só [14].

Por estas dificuldades, o conceito de *Elastic Optical Networking* (EON), ou redes ópticas elásticas, foi introduzido como um modo de oferecer uma utilização eficiente dos recursos ópticos disponíveis, sendo capaz de acomodar taxas de *bits* que variam desde alguns Gb/s até a magnitude de *terabits* por segundo [13, 16], além da alocação adaptável de recursos de *hardware* e espectrais de acordo com a demanda do tráfego [14]. Na literatura, os termos "flexível", "elástico", "flexgrid ou flexigrid", "gridless" e "adaptável" são usados intercambiavelmente. Esta alocação flexível é permitida graças ao uso de tecnologias como *Orthogonal Frequency Division Multiplexing* (OFDM), *Nyquist WDM* (N-WDM) e *Optical Arbitrary Waveform Generation* (OAWG) [13]. EONs têm sido amplamente aceitas como uma das melhores soluções com arquiteturas de rede flexíveis e capazes de alocar recursos de forma flexível [17].

A nível de design e otimização de *Elastic Optical Networks* (EONs), um dos principais desafios em seu desenvolvimento se trata da alocação eficiente de recursos. Algoritmos e ferramentas de planejamento de rede convencionais (WDM) não podem ser aplicados devido à natureza flexível das redes. Assim, de modo a aproveitar completamente a flexibilidade disponibilizada pelos avanços de tecnologias na camada física, novos algoritmos de alocação de recursos têm sido explorados [13, 18, 19, 20, 21]. Por exemplo, com flexibilidade apenas no número de subportadoras disponíveis para alocação técnicas de roteamento e alocação de espectro, *Routing and Spectrum Assignment* (RSA), devem ser usadas. Caso haja flexibilidade na seleção do formato de modulação, então técnicas de roteamento e atribuição de espectro com modulação adaptativa, *Routing, Modulation Level and Spectrum Allocation* (RMLSA), devem ser escolhidas.

A avaliação de desempenho de sistemas de comunicação óptica é um desafio para os pesquisadores. A dinamicidade e complexidade, especialmente em redes ópticas elásticas, torna inviável uma modelagem analítica precisa e o uso de ambientes reais para medições torna a avaliação bastante custosa, devido principalmente aos equipamentos e ferramentas envolvidos. Assim, a simulação é a alternativa disponível para atividades de teste, validação e avaliação de novos protocolos de controle para o ambiente de redes ópticas [22].

Diferentes ferramentas de simulação de redes ópticas elásticas foram desenvolvidas para auxiliar os pesquisadores a implementar, testar e analisar novos algoritmos ou soluções de problemas diferentes da área. Como por exemplo, *Optical Network Simulator* (ONS) [22], *ElasticO++* [23], *Complex Elastic Optical Network Simulator* (CEONS) [24] e *Net2Plan* [25].

Recentemente, com a crescente popularização do uso de *Machine Learning* (ML), ou aprendizagem de máquina, na academia, estudos sobre a aplicação de ML para solução de problemas relacionados a EONs também têm se popularizado.

Machine Learning é o estudo de algoritmos de computação que se auto-otimizam de acordo com um critério de desempenho, usando dados de exemplo ou a própria experiência [26, 27]. Em sua forma mais básica, o método de ML constitui-se em coletar dados relevantes ao domínio do problema a ser resolvido para serem usados por um algoritmo de aprendizagem, o modelo. Este modelo é definido com parâmetros iniciais que são otimizados automaticamente a partir do consumo dos dados coletados. O objetivo do modelo pode ser tanto preditivo, para realizar predições no futuro sobre dados potencialmente desconhecidos; descritivo, para obter-se conhecimento novo acerca dos dados; ou ambos [27, 28]. O processo de realizar predições é chamado de inferência.

Dentre recentes usos de ML em pesquisas relacionadas a EONs, pode-se citar a pesquisa de Yu et al., que desenvolveu uma estratégia RSA baseada em *Deep Learning* (DL) [17], ou aprendizagem profunda, um subgrupo de ML. Guilherme et al. desenvolveram um modelo de DL capaz de identificar estratégias RSA em EONs com 98% de acurácia [29]. Outras pesquisas acerca do uso de ML em problemas na área de EONs podem ser encontradas em [30] e [31].

Devido ao recente crescimento do uso de ML em pesquisas no campo de EONs, os simuladores de redes ópticas elásticas disponíveis na literatura ainda não possuem integração com modelos de ML para uso durante as simulações. O presente trabalho visa analisar na literatura atual as bibliotecas de ML capazes de importar modelos pré-treinados, especificamente no campo de aprendizagem profunda como o desenvolvido por Yu et al. [17], no contexto de integrá-las à execução de simulações de EONs.

1.1 Problema

Devido ao recente crescimento do uso de ML em pesquisas no campo de EONs, os simuladores de redes ópticas elásticas disponíveis na literatura ainda não possuem suporte nativo à execução de modelos de ML para uso durante as simulações. Assim, pesquisas que envolvem o uso de ML para a solução de problemas como RSA não possuem um *framework* definido para analisar o desempenho de seus algoritmos ou soluções.

1.2 Objetivos

O objetivo geral deste trabalho é a análise das bibliotecas de ML disponíveis na literatura, com foco na capacidade de execução de modelos de ML pré-treinados em simulações de EONs executadas por simuladores conhecidos na literatura, como o ONS [22]. Além disso, o trabalho visa contribuir também com a integração de simuladores com modelos por meio de uma interface genérica, evitando a necessidade de conhecer detalhes de implementação e permitindo que pesquisadores executem seus modelos como preferirem, precisando apenas implementar uma interface de comunicação.

Estes objetivos gerais serão atingidos por meio dos seguintes objetivos específicos:

- Estudar as bibliotecas existentes na literatura capazes de executar modelos de ML;
- Selecionar bibliotecas apropriadas para o caso de uso de integração com simuladores de EONs;
- Avaliar de forma quantitativa o desempenho das bibliotecas com métricas e parâmetros pré-definidos.
- Analisar os resultados das avaliações e elencar as bibliotecas recomendadas para diferentes casos de uso.
- Realizar uma implementação de integração de ML com o ONS como prova de conceito e contribuição para a comunidade acadêmica.

1.3 Contribuições

A partir das análises qualitativas e quantitativas das bibliotecas de *machine learning* populares na literatura, este trabalho contribui com diversas recomendações acerca de como adicionar suporte para uso de modelos de aprendizagem de máquina em simuladores de EONs, considerando diversos casos de uso de acordo com as necessidades do usuário.

Adicionalmente, são feitas contribuições ao repositório do simulador ONS, onde são realizadas as seguintes implementações: configuração do projeto para utilização do Maven como ferramenta de gerenciamento de projetos; implementação de funcionalidades que permitem a execução de modelos de forma nativa em Java, com as bibliotecas ONNX Runtime e Deeplearning4j; implementação da funcionalidade que permite a comunicação do ONS com um serviço externo por meio de HTTP, possibilitando a execução de modelos de ML de forma genérica. É esperado que estas implementações sejam a base para futuros estudos da aplicação de ML em EONs.

1.4 Organização do trabalho

O trabalho está organizado em 6 capítulos com os seguintes propósitos:

- Capítulo 2 - Introdução de conceitos considerados essenciais para o entendimento do trabalho. Serão descritos de forma mais profunda o uso de simuladores para pesquisas no campo de redes ópticas elásticas, conceitos de ML usados ao longo do trabalho e a metodologia de avaliação de desempenho utilizada neste trabalho.
- Capítulo 3 - Descrição das bibliotecas de ML populares na literatura, sendo explicadas suas principais características e o racional para a consideração delas ou não na análise de desempenho.
- Capítulo 4 - Descrição da avaliação de desempenho das bibliotecas selecionadas, como métricas utilizadas, carga de trabalho, a máquina em que os testes foram realizados, entre outros, além da análise dos resultados da avaliação.
- Capítulo 5 - Considerando o apresentado nos capítulos 3 e 4, serão descritas as recomendações para o suporte do uso de ML em simuladores de acordo com diferentes casos de uso, e as contribuições feitas para o *Optical Network Simulator* (ONS).
- Capítulo 6 - Será apresentado qual foi o resultado obtido nas avaliações e as recomendações que melhor satisfazem os objetivos da integração de modelos de ML com simuladores de redes ópticas elásticas.

Capítulo 2

Fundamentação Teórica

Este capítulo apresenta conceitos básicos fundamentais para o melhor entendimento do trabalho. Na seção 2.1 são introduzidos conceitos fundamentais de aprendizagem de máquina e uma breve descrição de suas principais categorias.

São introduzidos detalhes do funcionamento de simulações de EONs e a relevância deles para o trabalho, aprofundados são aprofundados conceitos de machine learning como suas aplicações, seu funcionamento e sua relevância para EONs. Por fim, na seção ??, são discutidos detalhes da execução de modelos de *deep learning* importantes para o entendimento de considerações feitas neste trabalho.

2.1 Aprendizagem de Máquina

Machine Learning (ML), ou aprendizagem de máquina é o estudo de algoritmos de computação que se auto-otimizam de acordo com um critério de desempenho, usando dados de exemplo ou a própria experiência [26, 27].

Em sua forma mais básica, o método de ML é a coleta de um grande número de dados do domínio do problema a ser resolvido e o uso deles em um algoritmo de aprendizagem, o modelo. Este modelo é definido com parâmetros iniciais que são otimizados com o consumo dos dados. O objetivo do modelo pode ser tanto preditivo, para realizar previsões no futuro sobre dados potencialmente desconhecidos, descritivo, para obter-se conhecimento novo acerca dos dados, ou ambos. O processo de obter resultados de um modelo é chamado de inferência, sejam eles preditivos ou descritivos.

Há dois grandes desafios no campo de ML: primeiramente, são necessários algoritmos eficientes para o problema de otimização do modelo inicial, de modo que a fase de treinamento seja completada em tempo viável; secundamente, uma vez que um modelo tenha sido aprendido, sua representação e solução algorítmica para a inferência também devem ser eficientes. [27] [28]

Normalmente, o campo de ML é dividido em três principais categorias: *supervised learning*; *unsupervised learning*; e *reinforcement learning*.

2.1.1 Aprendizado supervisionado

Em inglês, *supervised learning* é a categoria em que o conjunto de dados de entrada (*training set*) possui um mapeamento para o comportamento esperado, rotulado por um "supervisor"[27]. O objetivo é aprender uma regra geral que mapeie os valores de entrada para os respectivos valores esperados de saída. Os valores de saída podem ser contínuos (problemas de regressão) ou discretos (problemas de classificação) [32].

2.1.2 Aprendizado não-supervisionado

Em inglês, *unsupervised learning* é a categoria em que existe apenas o conjunto de dados de entrada e o objetivo é encontrar regularidades presentes nos mesmos [27]. Este tipo de aprendizagem é capaz de desempenhar várias tarefas, porém a mais comum é *clustering* [32].

Clustering é o processo de agrupar dados de modo que a similaridade de dados nos grupos (*clusters*) é alta, porém a similaridade de dados entre grupos diferentes é baixa. Esta similaridade é tipicamente expressada como uma função de distância, que depende do tipo de dados presente no conjunto [32].

Dentre os usos de aprendizagem não-supervisionada, pode-se destacar análise de redes sociais, agrupamento de genes e pesquisa de mercado como aplicações bem-sucedidas [32].

2.1.3 Aprendizado por reforço

Em inglês, *reinforcement learning* é a categoria em que o algoritmo de aprendizagem tem como objetivo aprender uma política de ações que maximizem a recompensa em um dado ambiente [27].

O paradigma de *reinforcement learning* permite que agentes explorem possíveis ações e refinem seu comportamento utilizando apenas uma avaliação, conhecida como recompensa, tendo como objetivo maximizar seu desempenho de longo prazo [32].

Esta técnica é comumente usada em aplicações como robótica, área de finanças como decisões de investimentos e gerenciamento de estoque [32].

2.2 Aprendizagem profunda

2.3 Simulações de EONs

2.4 Avaliações de Desempenho

Avaliações são importantes na busca pelo melhor desempenho de um sistema com os recursos disponíveis. Seus resultados auxiliam tanto nas decisões de escolhas entre diferentes sistemas ou simplesmente entender o funcionamento de um sistema já existente. Devido à grande diversidade de sistemas, não existe um procedimento padrão comum em que seja possível analisar eficientemente um sistema qualquer, sendo necessário conhecer o sistema a ser avaliado e escolher as métricas, carga de trabalho e técnicas de avaliação apropriadas [1].

Uma simulação executada por simuladores de EONs costuma envolver dezenas de milhares de eventos como requisições de conexões. Tamanha magnitude do número de eventos representa a importância de um bom desempenho na execução de modelos, como por exemplo em propostas de soluções para problemas de alocação de recursos (e.g. RSA) cujos modelos seriam executados em cada evento. Assim, uma análise quantitativa do desempenho de bibliotecas de ML é importante na busca por uma solução de integração de ML com simuladores que seja flexível de acordo com as necessidades de cada pesquisa e que possua um bom desempenho de modo a acelerar a obtenção de resultados.

Raj Jain em seu livro [1] propôs uma abordagem sistemática para a realização de análises de desempenho, descrita passo a passo nas próximas subseções.

2.4.1 Definição dos objetivos do estudo e do sistema

A primeira etapa se trata de definir o objetivo do estudo e os limites do sistema a ser analisado. A definição do sistema consiste em delinear os limites do sistema, como por exemplo uma biblioteca de serialização em JSON cujos serviços são funções para serializar e desserializar um conjunto de dados.

Definir o sistema e os objetivos do estudo é importante pois as métricas de desempenho e as cargas de trabalho usuadas na análise de desempenho depende da definição do sistema.

2.4.2 Listar serviços e resultados

Cada sistema fornece um conjunto de serviços, como as funções da biblioteca de serialização em JSON previamente mencionadas. Os serviços fornecidos pelo sistema possuem um conjunto de possíveis resultados que podem ou não ser desejáveis (i.e. erros). A listagem

Critério	Modelagem Analítica	Simulação	Medição
1. Estágio	Qualquer	Qualquer	Pós-protótipo
2. Tempo necessário	Pequeno	Médio	Variado
3. Ferramentas	Analistas	Ling. de programação	Instrumentação
4. Acurácia	Baixa	Moderada	Variada
5. Comparações	Fácil	Moderado	Difícil
6. Custo	Baixo	Médio	Alto
7. Vendabilidade	Baixo	Média	Alta

Tabela 2.1: Critérios para a seleção de uma técnica de avaliação de desempenho [1].

dos serviços e de seus resultados considerados é importante para definir as métricas e cargas de trabalho da análise de desempenho.

2.4.3 Selecionar métricas

As métricas são os critérios usados para avaliar o desempenho de um sistema ou comparar alternativas de sistema. Normalmente, as métricas são relacionadas à velocidade, acurácia e disponibilidade de serviços.

2.4.4 Listar parâmetros e fatores

A lista de parâmetros representa os componentes de uma análise de desempenho que podem afetar o desempenho. Esta lista pode ser dividida entre parâmetros de sistema, que podem incluir parâmetros de ambos tipos *software* e *hardware* e não variam entre instâncias do sistema e parâmetros de carga de trabalho, que podem variar entre instâncias, como por exemplos requisições de usuário.

Os fatores são os parâmetros que são variados durante a avaliação de desempenho, como por exemplo quantidade de usuários ou tipos de requisição, e os valores que cada um dos fatores pode assumir são chamados de níveis.

2.4.5 Escolher a técnica de avaliação

Há três métodos de avaliação de desempenho: modelagem analítica, simulação e medição [1]. A escolha de uma destas técnicas depende de vários critérios a serem considerados de acordo com o sistema a ser avaliado, como por exemplo o estágio do sistema, tempo disponível para a análise e a acurácia requerida. A tabela 2.1 lista de forma resumida as considerações para a escolha de uma técnica de avaliação de desempenho.

2.4.6 Selecionar carga de trabalho

A carga de trabalho consiste de uma lista de requisições de serviço do sistema e pode ser representada de diferentes modos de acordo com a técnica de avaliação escolhida.

Em avaliações realizadas por modelagem analítica, a carga de trabalho pode ser definida como a probabilidade de várias requisições. Para simulações, pode ser uma lista de requisições de usuário coletadas de um sistema real. Para medições, podem ser *scripts* automatizados representando usuários no sistema real. É de fundamental importância que a carga de trabalho represente casos de uso reais do sistema.

2.4.7 Desenho de experimentos

Ao definir a lista de fatores é necessário decidir uma sequência de experimentos que forneça o máximo de informações com o mínimo de esforço necessário. Existem várias formas de desenhar experimentos sendo os 3 mais comuns o desenho simples, desenho fatorial completo e desenho fatorial fracionário.

Em um desenho simples, o primeiro experimento é realizado com uma configuração comum do sistema e um fator é variado de cada vez. Este desenho não é eficiente estatisticamente e se os fatores interagirem entre si, pode levar a conclusões erradas.

Em um desenho fatorial completo, todas as combinações possíveis de todos os níveis de todos os fatores são considerados. A principal vantagem é que todas as combinações são examinadas permitindo a análise do impacto de cada fator, incluindo fatores secundários e suas interações. A principal desvantagem é o custo do estudo pelo alto número de experimentos a serem realizados. É comum a utilização de técnicas para reduzir o número de combinações e consequentemente o custo.

Desenhos fatorial fracionário são utilizados quando o número de experimentos necessário para a realização do fatorial completo é muito alto. Este desenho consiste em escolher um subconjunto (fração) das combinações de um fatorial completo, levando em conta o fato de que experimentos de um desenho fatorial completo são normalmente redundantes.

2.4.8 Apresentação de resultados

A última etapa se trata de apresentar os resultados de modo que seja facilmente entendido pelo público-alvo.

Capítulo 3

Análise de Bibliotecas

Pela visão de auxiliar pesquisadores em suas integrações de modelos de ML com simuladores de redes ópticas elásticas, as análises aqui feitas devem buscar o aumento de produtividade do pesquisador. Para isto, as tecnologias de ML analisadas serão avaliadas de forma qualitativa, sendo esta avaliação guiada pelas seguintes questões:

- Há algum custo para usar a tecnologia?
- O código da tecnologia é aberto?
- A tecnologia é ativamente mantida por *maintainers* e/ou pela comunidade?
- O uso da tecnologia é amplamente documentado?
- A instalação e uso da tecnologia é simples?
- A tecnologia permite a execução de modelos pré-treinados?
- A tecnologia permite a execução de modelos pré-treinados com outras tecnologias?

Nesta análise, apenas tecnologias com licenças de código aberto serão consideradas de modo que os pesquisadores tenham livre acesso às recomendações e sejam capazes de manipulá-las em seus projetos, caso seja necessário. Dentre essas, apenas tecnologias disponíveis para uso em programas Java ou Python serão consideradas.

A linguagem Java é amplamente utilizada para a implementação de simuladores de redes ópticas elásticas, como em [22], [24] e [25], por isto, a integração de modelos de ML de forma embutida no simulador permite uma integração performática ao excluir-se a necessidade de comunicação com outros serviços ou processos para executar os modelos.

A linguagem Python é a mais usada e priorizada para desenvolvimento em ML entre trabalhadores da área [33]. Assim, uma integração de simuladores com um processo ou serviço independente escrito em Python, responsável por executar os modelos, pode estar

sob um maior domínio de um pesquisador de ML na área de EONs, apesar do custo de tempo da execução graças ao tempo necessário para comunicação entre os processos ou serviços.

As tecnologias também devem ser fáceis de serem instaladas, configuradas e manipuladas de acordo com as necessidades de cada pesquisador. Para isto, é fundamental que suas APIs sejam bem documentadas e que a instalação exija o mínimo de modificações de configurações da máquina, externas ao simulador.

Por fim, é ideal que a análise considere a flexibilidade das bibliotecas à respeito dos diversos tipos de modelos de *machine learning*, uma vez que pesquisas sobre o uso de ML em EONs são diversas e podem utilizar diferentes técnicas [31].

3.1 OpenCV

OpenCV (Open Source Computer Vision Library) é uma biblioteca de código aberto voltada para visão computacional e aprendizagem de máquina, construída para fornecer uma infraestrutura comum para aplicações de visão computacional e acelerar o uso de percepção de máquina em produtos comerciais [34].

Apesar do foco principal de OpenCV ser visão computacional, a biblioteca possui um módulo de redes neurais profundas e interfaces para as linguagens Python e Java. Adicionalmente, também é possível realizar a importação de modelos serializados em diversos formatos, como Darknet [35], Torch7 [36], ONNX [37] e TensorFlow [38]. A API da biblioteca é extensamente documentada, porém com poucos tutoriais sobre o uso do módulo de DNNs, evidenciando o foco em problemas de visão computacional.

No quesito facilidade de instalação e configuração os resultados foram variados: Em Python, para a execução de modelos com apenas o uso da CPU a instalação se resume a instalar o pacote `opencv-python-headless`, a versão sem dependências de bibliotecas de interfaces de usuário gráficas, e está pronto para uso. Porém, se há interesse em utilizar a GPU na execução dos modelos, o processo de instalação se torna bastante complexo, sendo necessário compilar manualmente a biblioteca considerando diversas configurações do ambiente da máquina, de modo que a criação de uma solução generalizada se torne inviável.

Em Java, o processo de instalação é complexo independente do uso ou não de GPU, sendo necessário o mesmo processo de compilação manual do projeto considerando configurações da máquina, não havendo nenhuma integração com gerenciadores de pacotes populares como *Maven* ou *Gradle*.

Assim, pelas dificuldades presentes na instalação, o único uso de OpenCV considerado é o de Python com as execuções sendo realizadas apenas pela CPU da máquina, sem uso de GPU.

3.2 PyTorch

PyTorch é uma biblioteca de ML de código aberto que provê uma plataforma de pesquisas em aprendizagem profunda, oferecendo máxima flexibilidade e velocidade [39], sendo considerada a biblioteca de aprendizagem profunda que mais cresce no mundo [40].

A biblioteca possui suporte para Python e conta com ampla documentação de diversas práticas. Na análise da biblioteca, não foram encontrados métodos nativos de conversão de modelos de outros formatos para serem inferidos com o uso de PyTorch e por este motivo a biblioteca foi descartada.

3.3 Scikit Learn

Scikit-learn é uma biblioteca de código-aberto desenvolvida em Python que integra diversos algoritmos de ML para problemas supervisionados e não-supervisionados de média escala com ênfase em trazer ML para não-especialistas [41]. É uma biblioteca extremamente popular, principalmente entre iniciantes na área de ML, com desenvolvimento ativo na comunidade.

A biblioteca, com suporte apenas para Python, possui extensa documentação de modo a melhor auxiliar iniciantes. Pelo seu foco em simplicidade, a biblioteca não possui suporte para uso de GPU em treinos ou execuções de modelos. Para importação e exportação de modelos, a biblioteca conta apenas com serialização nativa de Python por meio da biblioteca *pickle*, não sendo possível importar modelos de outros formatos.

Apesar da facilidade de se desenvolver modelos de ML com *Scikit Learn*, o uso da biblioteca foi descartado pela falta de suporte ao uso de GPU e de importação de modelos pré-treinados salvos em formatos diversos.

3.4 TensorFlow

TensorFlow é uma interface para a expressão de algoritmos de ML e uma implementação para a execução de tais algoritmos [42]. Além da biblioteca principal (TensorFlow Core), a organização possui vários produtos para a execução de algoritmos de ML em larga-escala (TensorFlow Extended), execução de modelos em sistemas embarcados, mobile ou

de baixa potência (Tensorflow Lite) e execução de modelos em JavaScript, para ser usado em browsers ou em Node.js (TensorFlow.js).

TensorFlow é uma das bibliotecas mais populares na área de ML, sua biblioteca principal possui ampla documentação além de diversos guias e tutoriais desenvolvidos pela comunidade. Está em ativo desenvolvimento e tem o apoio de diversas empresas de tecnologia reconhecidas.

O uso de TensorFlow Extended está fora do escopo desta pesquisa pelo objetivo de integração com a execução de um simulador e não um sistema de larga-escala. TensorFlow Lite será avaliado de forma mais profunda na seção 3.6 e TensorFlow.js também está fora do escopo por ser exclusivo para JavaScript. Restando apenas considerar a biblioteca principal, que possui suporte para Python, C, Go e Java.

O suporte para Java está em uma fase de transição, onde a biblioteca antiga está depreciada para uso e a biblioteca nova ainda está em fase experimental. O uso da biblioteca em fase experimental é complexo e não existe quase nenhuma documentação, sendo encontrada até uma recomendação de ler os testes unitários da implementação para aprender como usar certos elementos da API [43]. Por estes motivos, o uso de TensorFlow em Java foi descartado.

O suporte para Python é a base da implementação da biblioteca, logo a biblioteca de Python satisfaz todos os requisitos de nossa análise qualitativa, pelo que mencionado anteriormente nesta seção, sendo considerada para execução de modelos com e sem GPU, utilizando a biblioteca Keras como a API de alto nível para implementação do programa de simulação.

3.5 Keras

Keras [44] é uma biblioteca de *deep learning* de alto nível, desenvolvida usando a plataforma Tensorflow como base, sendo seu foco principal a capacidade de fácil experimentação.

A biblioteca é uma interface de alto nível para a criação e execução de modelos, instalada por meio da biblioteca do TensorFlow, sendo então utilizada como interface para a implementação do programa de simulação responsável por avaliar o desempenho da biblioteca TensorFlow.

3.6 TensorFlow Lite

TensorFlow Lite [45] é uma *framework* de aprendizagem profunda para execução de modelos em dispositivos. Se trata da versão da popular *framework* TensorFlow que é projetada

para execuções em dispositivos com menor poder computacional.

A importação de gráficos é limitada apenas a arquivos do tipo TFLite, porém existem ferramentas para realizar a conversão de formatos comuns em Tensorflow, como Keras e SavedModel. Atualmente, a biblioteca não fornece suporte a execução com uso de GPUs NVIDIA [46].

Tendo os fatores acima em consideração, a instalação e uso da biblioteca são simples e amplamente documentados para programas Python. Para a instalação, é necessário instalar a versão do pacote específica para a versão do interpretador Python instalado na máquina, sendo possível configurar uma detecção automática. A biblioteca não possui versões para uso em programas Java que não sejam voltados para Android.

Apesar da limitação de importação de modelos e a impossibilidade de uso em programas Java, TensorFlow Lite será avaliado de forma quantitativa pelo seu foco específico de execução rápida de modelos em dispositivos de borda.

3.7 ONNX Runtime

A ONNX Runtime [47] se trata de um acelerador de treinamento e execução de modelos de ML salvos em formatos ONNX [37]. *Open Neural Network Exchange* (ONNX) é um formato aberto construído para ser uma representação comum de modelos de ML, possuindo amplo suporte em s bibliotecas de ML.

A ONNX Runtime é desenvolvida com foco em suporte cross-plataforma, fornecendo uma API comum para diversas linguagens como C, C++, Java e Python. Seu desenvolvimento é apoiado por diversas empresas como Microsoft, Facebook, IBM, Intel, NVIDIA, entre outras.

Graças ao foco de implementações cross-plataforma, a instalação das bibliotecas para Java e Python são simples e exigem pouca ou nenhuma configuração. Em ambos os casos, é necessário apenas instalar o respectivo pacote caso a intenção seja usar apenas a CPU para inferências. Se houver interesse em usar uma GPU NVIDIA, é necessário instalar a versão da *runtime* compatível com a versão de CUDA instalada.

A documentação da biblioteca possui poucos guias ou tutoriais mas conta com diversos exemplos de código em Python para operações comuns e um exemplo de código em Java, além da completa referência dos pacotes de ambas versões da biblioteca.

Apesar da documentação limitada, a ONNX Runtime será considerada na avaliação de desempenho pela alta portabilidade da biblioteca, sendo ideal para atender aos diferentes casos de uso de pesquisas de ML em EONs.

3.8 Deeplearning4j

Eclipse Deeplearning4j [48] é uma biblioteca de código-aberto para aprendizagem de máquina distribuída, disponível para Java e Scala. Seu desenvolvimento está ativo e é conduzido pela empresa Konduit.

A biblioteca possui ampla documentação da API e diversos tutoriais que explicam os diferentes usos da biblioteca. É possível importar modelos no formato ONNX, HDF5 e TensorFlow, além de seu próprio formato.

A instalação da biblioteca é extremamente simples para uso de CPU e se dá por meio do gerenciador de pacotes Maven, sendo necessário apenas adicionar apenas algumas linhas na configuração do projeto para que seja possível executar o Deeplearning4j. Para uso de GPU, apenas máquinas com placas de vídeo NVIDIA e com CUDA configurado são suportadas. Neste caso, o processo de instalação é quase o mesmo, tendo como diferença o identificador da biblioteca que depende da versão da GPU instalada na máquina.

A biblioteca Deeplearning4j será avaliada em um programa Java com uso de ambas CPU e GPU.

3.9 MXNet

A biblioteca MXNet [49] é uma *framework* de código-aberto para aprendizagem profunda que permite a definição, o treinamento e a execução de redes neurais profundas em diversas plataformas, estando atualmente em desenvolvimento, em processo de incubação pela Apache Incubator. Se trata de uma biblioteca bastante versátil, com suporte à diversas linguagens, incluindo Java e Python, e importação de modelos em formato ONNX para execução.

Entretanto, o suporte para Java é limitado primeiramente no quesito disponibilidade de bibliotecas. Alguns arquivos binários presentes no pacote possuem licenças incompatíveis com a licença Apache 2, resultado na retirada dos pacotes de Java do repositório Maven. Assim, para utilizar uma versão atualizada da biblioteca é necessário compilar o código-fonte. Além disso, a documentação para Java também é quase vazia, tendo apenas dois tutoriais simples e a publicação da referência da API. Pela dificuldade de instalação e a falta de tutoriais e suporte da comunidade, o uso de MXNet para Java foi descartado.

A versão em Python da biblioteca MXNet é bastante completa, contando com diversos tutoriais para diferentes casos de uso, além de prover uma fácil instalação por meio do gerenciador de pacotes *pip*. Entretanto, em testes iniciais para avaliar a viabilidade de uso da biblioteca, foi descoberto que a biblioteca dispara erros ao tentar executar o modelo

usado pelo autor [29] para a comparação de desempenho entre as bibliotecas, logo o uso de MXNet para Python também foi descartado.

3.10 Outras tecnologias

Além das bibliotecas previamente mencionadas, outras bibliotecas foram brevemente avaliadas mas descartadas por motivos desclassificatórios, como Paddle Lite, cuja documentação está disponível apenas em chinês, a biblioteca Caffe2 disponível para Python que foi descontinuada em favor de PyTorch, entre outras não disponíveis para Python ou Java ou sem atual expressão na literatura.

Capítulo 4

Avaliação de Desempenho

Este capítulo tem como objetivo apresentar a metodologia da avaliação de desempenho das diferentes bibliotecas de ML selecionadas.

4.1 Metodologia

A avaliação de desempenho seguirá a abordagem sistemática para a realização de avaliações de desempenho, proposta por Raj Jain e descrita na seção 2.4.

O objetivo desta análise consiste em comparar diversas bibliotecas de aprendizagem de máquina, utilizadas em programas Java e Python, de modo a escolher a melhor alternativa no quesito velocidade na realização de inferência de modelos de ML.

O sistema a ser avaliado consiste de um módulo de programação, programado em Python ou Java de acordo com a análise realizada no capítulo 3, que fornece um serviço de inferência de modelos pré-treinados e carregados em memória, onde ao receber dados de entrada de um tipo especificado pelo modelo, executa o modelo com a entrada recebida e retorna o valor inferido do modelo.

Nesta análise, erros e falhas durante a execução do serviço não serão consideradas. Em cada execução do serviço, serão registrados o tempo de total de execução e o resultado da mesma. As alternativas serão comparadas de acordo com o tempo de execução por chamada, devido ao interesse em diminuir o tempo de execução para inferência de modelos. Além disso, os resultados das inferências realizadas por cada alternativa serão comparados entre si para verificar se há perda ou ganho de precisão do modelo, de acordo com o formato em que se encontra serializado e a biblioteca de ML utilizada para a execução.

Assim, diversos parâmetros influenciam o desempenho do sistema:

- Velocidade da CPU da máquina;

- Velocidade e funcionalidades da GPU da máquina, em execuções de modelo que utilizam a GPU para inferência;
- Formato de serialização em que o modelo está salvo;
- Biblioteca utilizada para a execução do modelo;
- Uso ou não da GPU para a execução do modelo;
- Número, tamanho e valor dos dados de entrada de uma execução de modelo;
- Número e tamanho dos dados de saída de uma execução de modelo;
- Ambiente de execução, ou *runtime environment* em que o programa é executado.

Dentre estes parâmetros, foram selecionados três fatores:

- Ambiente de execução. Serão executados programas escritos em Python, executados com *runtime* Python 3.8.5, e em Java, executados com *runtime* OpenJDK 11.0.7+10.
- Biblioteca utilizada para a execução do modelo. Como avaliado na seção 3, serão consideradas as bibliotecas ONNX Runtime, Tensorflow Lite, TensorFlow, OpenCV e Deeplearning4j.
- Uso de GPU. Haverão experimentos com uso de GPU na execução dos modelos e sem o uso de GPU.
- Formato de serialização em que o modelo está salvo. Onde será utilizado preferencialmente o arquivo original do modelo, em formato HDF5, e outros arquivos convertidos quando necessário, em formatos ONNX e TensorFlow Lite.

A medição será a técnica de avaliação de desempenho escolhida pelo fato do autor se especializar em programação. Assim, as diferentes alternativas de sistemas a serem comparadas serão implementadas e instrumentadas na execução da análise de desempenho, sendo cada uma das implementações um programa desenvolvido em Python ou Java.

Para a simulação, um classificador de estratégias de RSA em EONs, baseado em *deep learning*, será utilizado para comparação. Este modelo recebe como entrada o estado de uma EON e tem como saída a classificação da estratégia RSA em utilização, de acordo com o estado. O modelo possui como saída uma classificação da estratégia de alocação identificada pelo estado como ruim, média ou boa.

A carga de trabalho é formada por 97301 requisições onde os dados de cada entrada correspondem a estados de rede coletados em execuções do ONS, sendo cada estado representado por uma matriz de 86 linhas e 320 colunas, a representação da topologia USANet

com 24 nós e 86 enlaces em que cada enlace contém 320 *slots*. As primeiras 3000 requisições possuem o propósito de *aquecer* os ambientes de execução, isto é, garantir que todo o código a ser executado já está compilado pelo ambiente de execução, que os recursos apropriados já foram alocados, que o lixo de memória inicial da aplicação já foi coletado, entre outros. Portanto, os resultados das primeiras 3000 requisições serão descartados na análise final.

Os experimentos a serem realizados consistem em um desenho fatorial fracionário, onde diversas combinações foram descartadas por incompatibilidade de fatores, como o uso de Deeplearning4j em Python, ou motivos diversos detalhados no capítulo 3. Assim, serão realizadas as seguintes combinações de experimentos:

- Java, Deeplearning4j, sem GPU, modelo original no formato HDF5 (TensorFlow);
- Java, Deeplearning4j, com GPU, modelo original no formato HDF5 (TensorFlow);
- Java, ONNX Runtime, sem GPU, modelo convertido para o formato ONNX;
- Java, ONNX Runtime, com GPU, modelo convertido para o formato ONNX;
- Python, OpenCV, sem GPU, modelo convertido para o formato ONNX;
- Python, Tensorflow Lite, sem GPU, modelo convertido para o formato TFLite;
- Python, Tensorflow, sem GPU, modelo original no formato HDF5 (TensorFlow);
- Python, Tensorflow, com GPU, modelo original no formato HDF5 (TensorFlow);
- Python, ONNX Runtime, sem GPU, modelo convertido para o formato ONNX;
- Python, ONNX Runtime, com GPU, modelo convertido para o formato ONNX.

Cada elemento da carga de trabalho foi executado 5 vezes por todas as combinações de simulação, sendo selecionada a mediana de cada uma destas 5 execuções com o objetivo de remover ruídos arbitrários causados pela máquina durante a execução.

4.2 Ambiente de Execução

Para a realização das medições, 10 programas foram desenvolvidos considerando todas as combinações descritas anteriormente. Estes programas realizam o mesmo conjunto de tarefas: 1. inicializar o sistema ao carregar o modelo; 2. inicializar procedimentos necessários para a execução da carga de trabalho; 3. carregar a carga de trabalho usada como entrada do modelo; 4. realizar as chamadas de serviço com as entradas carregadas para executar o modelo, registrando o tempo de execução e o resultado. Cada programa

trata de medir apenas o intervalo de tempo em que a execução do modelo ocorre. A execução de um dos programas foi orquestrada por *scripts* auxiliares feitos em Python, responsáveis por instalar dependências, e executar os programas de simulação.

As simulações foram realizadas em uma máquina com processador Intel Core i3-8100, placa de vídeo GeForce RTX 2060 e memória RAM de 32 GB (2x16GB 3000Mhz DDR4). O código-fonte dos programas de simulação e de programas auxiliares pode ser encontrado na url `tcc.mikaelmello.com`.

4.3 Resultados

Após as medições, observa-se que a execução do modelo em um programa Java, sem o uso de GPU e com a biblioteca Deeplearning4j exibe os melhores resultados possuindo tempos de execução menores do que sua alternativa com GPU e pelo menos duas vezes mais rápido que qualquer uma das outras bibliotecas avaliadas, como é possível observar na figura 4.1 e na tabela 4.1.




Figura 4.1: Tempo de execução de execuções sequenciais do modelo para cada combinação

De acordo com a tabela 4.1, a execução do modelo com a biblioteca Deeplearning4j em Java é a mais rápida em média, de modo que a execução sem uso de GPU é em média 270

ling.	biblioteca	GPU	média	desvio padrão	mínimo	máximo
Python	OpenCV	sem	1773.14	12.42	1729	1972
		com	2885.55	18.72	2827	3219
	TensorFlow	sem	2988.96	19.54	2940	3332
		com	2083.75	12.21	2043	2218
	ONNX Runtime	sem	2106.01	12.31	2060	2276
		com	1767.84	10.62	1729	1902
Java	ONNX Runtime	sem	2366.02	153.21	2322	23961
		com	2067.64	12.67	2041	2383
	Deeplearning4j	sem	763.44	69.23	722	11749
		com	1026.51	33.67	990	1629

Tabela 4.1: Estatísticas descritivas acerca do tempo de execução (microsegundos) do modelo em todas as combinações.

microsegundos mais rápida que a execução com GPU, porém possui um desvio padrão muito maior devido a diversas limitações deste caso de uso: execuções em CPU estão mais sujeitas a interrupções externas, como por exemplo o coletor de lixo da JVM ou trocas de contexto do sistema operacional. O mesmo comportamento de alta variância em CPU é observável nas execuções de ONNX Runtime em Java.

A simulação com a biblioteca ONNX Runtime, sendo a única presente em programas Java e Python, foi importante para observar o melhor desempenho de programas Python em versões que utilizam e não utilizam a GPU para inferência.

As simulações com bibliotecas da família TensorFlow mostram um desempenho expressivamente maior da biblioteca TensorFlow Lite, evidenciando o fato de que Tensorflow Lite é uma biblioteca desenvolvida especificamente para melhores desempenhos em inferências de modelos, comparada com TensorFlow.

As simulações de ambas bibliotecas ONNX Runtime e TensorFlow mostram uma melhora de desempenho significativa ao utilizar a GPU da máquina para a execução dos modelos, com ganhos que variam de 100 a 300 microsegundos em média, ao contrário de Deeplearning4j que se mostrou mais devagar com o uso da GPU. Apesar da GPU ser em geral mais rápida na execução de modelos pelas suas características, um dos motivos para este cenário acontecer é a presença de sobrecarga adicional de tempo ao transferir dados da CPU para a GPU, mais significativa quando o tempo de execução do Deeplearning4j na CPU é em média de duas a três vezes menor comparado com as outras bibliotecas.

Também é possível observar que o tempo de execução para as combinações "Python, ONNX Runtime, sem GPU", "Python, TensorFlow Lite, sem GPU" e "Java, ONNX Runtime, com GPU" é virtualmente igual. Assim como os tempos das combinações "Python, OpenCV, sem GPU" e "Python, ONNX Runtime, com GPU", apesar deste último par

possuir 300 microsegundos a menos de tempo de execução em média. Após estudos e experimentos adicionais, não foi possível achar uma explicação satisfatória para a inesperada similaridade entre combinações tão diversas.

Capítulo 5

Propostas de Integração

A área de aprendizagem de máquina é extensa e diversa, modelos são em sua maioria desenvolvidos de forma personalizada para um problema único que buscam resolver. Esta diversidade é refletida na atual literatura sobre o uso de ML em EONs. Pesquisas como [31] e [32] mostram as diversas aplicações em diferentes problemas de EONs, apesar da pesquisa na área estar em sua infância.

Ao propor soluções que busquem auxiliar pesquisadores no uso de ML em simuladores, é necessário considerar os diversos casos de uso e suas características, fundamentais para definir a importância de fatores como desempenho do tempo de execução, facilidade de execução, disponibilidade da GPU, entre outros. Para isto, este trabalho focará suas contribuições em duas categorias, propostas de integração focadas em flexibilidade e facilidade de uso do usuário e propostas de integração focadas em um melhor desempenho na execução dos modelos.

5.1 Flexibilidade

No campo de aprendizagem de máquina, é comum que haja um constante refinamento de modelos em desenvolvimento, havendo várias iterações de testes e modificações de parâmetros de modo a maximizar o desempenho do modelo, avaliado em métricas apropriadas. Nestes casos, uma integração em que o pesquisador precisa constantemente exportar o modelo para carregá-lo em um simulador acaba se tornando trabalhosa. Além de exportar o modelo, ainda seria necessário modificar o simulador, possivelmente desenvolvido em uma linguagem não dominada pelo pesquisador, para que colete métricas relevantes ao processo de desenvolvimento do modelo.

Assim, a implementação de interfaces genéricas de comunicação em simuladores é uma boa alternativa para pesquisadores que desejam manter o controle sobre o ambiente

de desenvolvimento e execução de seus modelos de aprendizagem de máquina e ainda assim integrá-los facilmente com simuladores.

Nesta solução, o simulador é programado para buscar a inferência de um modelo por meio de uma interface pré-definida, como por exemplo chamadas em HTTP para um servidor configurado, e o pesquisador é responsável por implementar a interface no serviço que executa o modelo, neste exemplo um servidor HTTP. Assim, o pesquisador mantém o controle sobre o ambiente deste modelo, sendo capaz de coletar quaisquer métricas relevantes de execução como os valores de entrada e saída, tempo de execução, entre outros, e sem precisar constantemente exportar o modelo e carregá-lo no simulador a cada rodada de testes.

Sua principal desvantagem consiste em maiores tempos de execução do modelo, do ponto de vista do simulador. Isto acontece pela sobrecarga de operações para transferir os dados de entrada e saída do modelo entre processos além da latência presente na comunicação entre serviços. Esta sobrecarga adicional de tempo de execução pode ser significativa ou não, dependendo de vários fatores acerca do estudo sendo realizado e do modelo sendo desenvolvido.

5.2 Desempenho

A solução com foco em desempenho busca diminuir o tempo total de execução de modelos, o que torna importante que os modelos possam ser executados de forma nativa pelo simulador uma vez que isto elimina a sobrecarga de tempo por comunicação externa.

Para simuladores desenvolvidos em Java, vimos no capítulo 4 que para o modelo selecionado, executá-lo com a biblioteca Deeplearning4j sem o uso de GPU exibiu o melhor desempenho. A biblioteca ONNX Runtime, apesar de mais lenta, também é atrativa por permitir a importação de modelos no formato ONNX, um formato popular e capaz de ser o alvo de conversão de diversos outros formatos existentes na literatura.

Em Python, a biblioteca ONNX Runtime com o uso de GPU exibiu um desempenho tão bom quanto OpenCV sem o uso de GPU. Ambas combinações possuem suas vantagens e desvantagens em relação a facilidade e flexibilidade no uso: OpenCV é voltada para uso na área de visão computacional, o que torna o uso dela em outros contextos sub-ótimo se ela não for a melhor escolha no quesito desempenho; ONNX Runtime precisa do uso da GPU para ter um desempenho tão bom quanto OpenCV com este modelo, porém tem suporte para fácil configuração de uso da GPU e uma API mais amigável.

5.3 Contribuições ao ONS

Este trabalho oferece uma proposta de implementação para o *Optical Network Simulator* (ONS), com implementações para interfaces e classes que definem a arquitetura do uso de modelos de aprendizagem de máquina no simulador.

No quesito flexibilidade, foi implementada uma classe genérica de comunicação HTTP configurável por 3 parâmetros: tipo dos dados de entrada do modelo, tipo dos dados de saída do modelo e a URL em que o modelo está sendo servido. Esta classe fornece um método para execução dos modelos, que recebe a entrada do tipo pré-definido, a serializa e faz a requisição para a URL. A resposta da requisição deve ser em JSON e é então desserializada de modo a obter o valor encapsulado e retornado ao chamador da função.

No quesito desempenho, são propostas implementações de interfaces e classes para a execução nativa de modelos. A princípio, foram implementados os fluxos de carregamento de modelos nas bibliotecas Deeplearning4j e ONNX Runtime.

Por fim, foram implementadas integrações do modelo utilizado na avaliação de desempenho deste trabalho com as 3 contribuições aqui presentes: carregamento e execução do modelo com as bibliotecas Deeplearning4j e ONNX Runtime, além do uso da interface focada em flexibilidade que fará requisições para um servidor local. A classe `FF_Classifier` possui a implementação de um algoritmo RSA que, além de definir a ação sobre a chegada de um novo fluxo, envia o estado da topologia da rede para as 3 implementações e imprime suas saídas, a classificação do algoritmo RSA, e o tempo levado na execução de cada uma delas.

Com estas contribuições, espera-se que atuais usuários do ONS possam utilizar modelos de ML pré-treinados em suas simulações, e que pesquisadores de ML na área de EONs sintam-se incentivados a utilizar o ONS para auxiliar-los em suas pesquisas.

Capítulo 6

Conclusão

Com a crescente demanda de tráfego global, *Elastic Optical Networking* (EON) surgiu como uma nova solução para o gerenciamento eficiente de recursos em redes ópticas. Uma das principais ferramentas de pesquisa em EONs são os simuladores, ideais pelo baixo custo e baixa complexidade de implementação.

Pelo crescente desenvolvimento de ambas áreas de *Elastic Optical Networks* (EONs) e *Machine Learning* (ML), o estudo das aplicações de algoritmos de aprendizagem de máquina em redes ópticas elásticas tem se popularizado. Entretanto, pelo fato de esta área de pesquisa ainda estar em seus estágios iniciais, há lacunas a serem preenchidas na academia, como por exemplo a falta de suporte a execução de modelos de ML em simuladores de EONs.

Este trabalho teve como objetivo analisar a literatura atual de bibliotecas de ML para propor soluções a respeito da implementação de suporte dos simuladores à execução de ML.

Para isso, fez-se uma análise qualitativa de diversas bibliotecas populares, filtrando-as por critérios como facilidade de instalação e configuração, documentação, e disponibilidade. Em seguida, o desempenho das bibliotecas selecionadas foi avaliado tendo como critério o tempo de execução de um modelo pré-selecionado.

Na análise de desempenho, a biblioteca Deeplearning4j apresentou o melhor desempenho ao ser comparada com outras alternativas. Em ambientes de execução Python, ONNX Runtime (com GPU) e OpenCV (sem GPU) apresentaram os melhores desempenhos.

Este trabalho por fim apresentou recomendações e direções acerca de implementações de suporte de aprendizagem de máquina a simuladores de redes ópticas elásticas, onde interfaces genéricas de comunicação foram recomendadas para casos de uso que exigem alta flexibilidade na integração de modelos, como por exemplo modelos ainda sendo desenvolvidos, e bibliotecas nativas de alto desempenho foram recomendadas, como Deeplearning4j para simuladores em Java, para casos de uso que exigem alto desempenho.

Por fim, foram apresentadas contribuições de implementações para adicionar ao *Optical Network Simulator* (ONS) o suporte para uso de modelos de aprendizagem de máquina em suas simulações. Estas contribuições cobrem ambos casos em que ou a flexibilidade ou o desempenho são priorizados, sendo fornecido o código-fonte por meio de um repositório hospedado na plataforma GitHub.

Referências

- [1] Jain, R.: *The Art of Computer Systems Performance Analysis: Techniques for Experimental Design, Measurement, Simulation, and Modeling*. Wiley, 1991, ISBN 978-0-471-50336-1. x, 8, 9
- [2] Le Rouzic, E.: *Network evolution and the impact in core networks*. Em *36th European Conference and Exhibition on Optical Communication*, páginas 1–8, 2010. 1
- [3] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2010–2015*. Growth Lakeland, 2011. 1
- [4] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2011–2016*. Growth Lakeland, 2012. 1
- [5] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2012–2017*. Growth Lakeland, 2013. 1
- [6] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2013–2018*. Growth Lakeland, 2014. 1
- [7] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2014–2019*. Growth Lakeland, 2015. 1
- [8] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2015–2020*. Growth Lakeland, 2016. 1
- [9] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2016–2021*. Growth Lakeland, 2017. 1
- [10] Cisco, T: *Cisco visual networking index: Forecast and methodology, 2017–2022*. Growth Lakeland, 2018. 1
- [11] Ericsson: *Q2 2020 update*. Ericsson Mobility Report, Sep 2020. <https://www.ericsson.com/4a4e5d/assets/local/mobility-report/documents/2020/emr-q2-update-03092020.pdf>. 1
- [12] McKeay, Martin: *The building wave of internet traffic*. Akamai Security Intelligence & Threat Research Blog, Apr 2020. <https://blogs.akamai.com/sitr/2020/04/the-building-wave-of-internet-traffic.html>. 1
- [13] Tomkos, I., S. Azodolmolky, J. Solé-Pareta, D. Careglio e E. Palkopoulou: *A tutorial on the flexible optical networking paradigm: State of the art, trends, and research challenges*. *Proceedings of the IEEE*, 102(9):1317–1337, 2014. 1, 2

- [14] Jinno, M.: *Elastic optical networking: Roles and benefits in beyond 100-gb/s era*. Journal of Lightwave Technology, 35(5):1116–1124, 2017. 1, 2
- [15] Jorge López Vizcaíno, Yabin Ye e I. T. Monroy: *Energy efficiency in elastic-bandwidth optical networks*. Em *2011 International Conference on the Network of the Future*, páginas 107–111, 2011. 1, 2
- [16] Tomkos, I., E. Palkopoulou e M. Angelou: *A survey of recent developments on flexible/elastic optical networking*. Em *2012 14th International Conference on Transparent Optical Networks (ICTON)*, páginas 1–6, 2012. 2
- [17] Yu, J., B. Cheng, C. Hang, Y. Hu, S. Liu, Y. Wang e J. Shen: *A deep learning based rsa strategy for elastic optical networks*. Em *2019 18th International Conference on Optical Communications and Networks (ICOON)*, páginas 1–3, 2019. 2, 3
- [18] Christodoulopoulos, K., I. Tomkos e E. A. Varvarigos: *Elastic bandwidth allocation in flexible ofdm-based optical networks*. Journal of Lightwave Technology, 29(9):1354–1366, 2011. 2
- [19] Klinkowski, M. e K. Walkowiak: *Routing and spectrum assignment in spectrum sliced elastic optical path network*. IEEE Communications Letters, 15(8):884–886, 2011. 2
- [20] Costa, Lucas R. e André C. Drummond: *Novo algoritmo rmlsa com roteamento multihop em redes Ópticas elásticas*. Em *Anais do XXXIV Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*. SBC, 2016. <http://www.sbrc2016.ufba.br/downloads/SessoesTecnicas/152171.pdf>. 2
- [21] Costa, Lucas R. e André C. Drummond: *Novo esquema para provisão de modulação adaptativa em redes Ópticas elásticas*. Em *Anais do XXXV Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*, Porto Alegre, RS, Brasil, 2017. SBC. <https://sol.sbc.org.br/index.php/sbrc/article/view/2662>. 2
- [22] Costa, Lucas R, Léia S de Sousa, Felipe R de Oliveira, Kaio A da Silva, Paulo JS Júnior e André C Drummond: *Ons: Simulador de eventos discretos para redes ópticas wdm/eon*. Salão de Ferramentas do Simpósio Brasileiro de Redes de Computadores-SBRC, 2016. 2, 3, 4, 11
- [23] Tessinari, Rodrigo Stange, Bart Puype, Didier Colle e Anilton Salles Garcia: *Elastic++: An elastic optical network simulation framework for omnet++*. Optical Switching and Networking, 22:95 – 104, 2016, ISSN 1573-4277. <http://www.sciencedirect.com/science/article/pii/S1573427716300571>. 3
- [24] Aibin, M. e M. Blazejewski: *Complex elastic optical network simulator (ceons)*. Em *2015 17th International Conference on Transparent Optical Networks (ICTON)*, páginas 1–4, 2015. 3, 11
- [25] Pavon-Marino, P. e J. Izquierdo-Zaragoza: *Net2plan: an open source network planning tool for bridging the gap between academia and industry*. IEEE Network, 29(5):90–96, 2015. 3, 11

- [26] Mitchell, Thomas M.: *Machine Learning*. McGraw-Hill, Inc., USA, 1ª edição, 1997, ISBN 0070428077. 3, 6
- [27] Alpaydin, E.: *Introduction to Machine Learning*. Adaptive Computation and Machine Learning series. MIT Press, 2020, ISBN 9780262043793. <https://books.google.com.br/books?id=tZnSDwAAQBAJ>. 3, 6, 7
- [28] Simeone, O.: *A very brief introduction to machine learning with applications to communication systems*. IEEE Transactions on Cognitive Communications and Networking, 4(4):648–664, 2018. 3, 6
- [29] Silva, Guilherme, Lucas R. Costa e André C. Drummond: *Classificador baseado em aprendizado profundo para identificação de estratégias de alocação de espectro em redes Ópticas elásticas*. Em *Anais do XXXVIII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*. SBC, 2020. <https://sol.sbc.org.br/index.php/sbrc/article/download/12293/12158>. 3, 17
- [30] Choudhury, P. D. e T. De: *Recent developments in elastic optical networks using machine learning*. Em *2019 21st International Conference on Transparent Optical Networks (ICTON)*, páginas 1–3, 2019. 3
- [31] Zhang, Yongjun, Jingjie Xin, Xin Li e Shanguo Huang: *Overview on routing and resource allocation based machine learning in optical networks*. Optical Fiber Technology, 60:102355, Dec 2020. 3, 12, 24
- [32] Musumeci, F., C. Rottondi, A. Nag, I. Macaluso, D. Zibar, M. Ruffini e M. Tornatore: *An overview on application of machine learning techniques in optical networks*. IEEE Communications Surveys Tutorials, 21(2):1383–1408, 2019. 7, 24
- [33] Wilcox, Mark, Stijn Schuermans, Christina Voskoglou e Alexandre Sabolevski: *State of the developer nation 12th edition - q1 2017*, Mar 2017. <https://www.developereconomics.com/resources/reports/state-of-the-developer-nation-q1-2017>. 11
- [34] *Opencv - about*. <https://web.archive.org/web/20201104030111/https://opencv.org/about/>, Accessed: 2020-11-08. 12
- [35] *Darknet: Open source neural networks in c*. <https://web.archive.org/web/20201101011701/https://pjreddie.com/darknet/>, Accessed: 2020-11-08. 12
- [36] *Torch / scientific computing for luajit*. <https://web.archive.org/web/20201101135030/https://torch.ch/>, Accessed: 2020-11-08. 12
- [37] *Onnx*. <https://web.archive.org/web/20201105074026/https://onnx.ai/>, Accessed: 2020-11-08. 12, 15
- [38] *Tensorflow*. <https://web.archive.org/web/20201108012745/https://www.tensorflow.org/>, Accessed: 2020-11-08. 12
- [39] PyTorch: *What is pytorch?* https://pytorch.org/tutorials/beginner/blitz/tensor_tutorial.html#what-is-pytorch. 13

- [40] Gugger, Sylvain e Jeremy Howard: *Practical deep learning for coders*. <https://web.archive.org/web/20201103183225/https://course.fast.ai/>, Accessed: 2020-11-08. 13
- [41] Pedregosa, F., G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot e E. Duchesnay: *Scikit-learn: Machine learning in Python*. Journal of Machine Learning Research, 12:2825–2830, 2011. 13
- [42] Abadi, Martín, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dandelion Mané, Rajat Monga, Sherry Moore, Derek Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu e Xiaoqiang Zheng: *TensorFlow: Large-scale machine learning on heterogeneous systems*, 2015. <https://www.tensorflow.org/>, Software available from tensorflow.org. 13
- [43] *Getting start tutorial - issue #68 - tensorflow/java*, Oct 2020. <https://github.com/tensorflow/java/issues/68#issuecomment-704622036>. 14
- [44] Chollet, François *et al.*: *Keras*. <https://keras.io>, 2015. 14
- [45] *Tensorflow lite / ml for mobile and edge devices*. <https://web.archive.org/web/20201104084527/https://www.tensorflow.org/lite>, Accessed: 2020-11-08. 14
- [46] *Is tf lite optimized for nvidia gpu's and intel cpus?* <http://web.archive.org/web/20201108062538/https://github.com/tensorflow/tensorflow/issues/34536>, Accessed: 2020-11-08. 15
- [47] *Onnx runtime*. <https://web.archive.org/web/20201107081602/https://microsoft.github.io/onnxruntime/>, Aceded: 2020-11-10. 15
- [48] *Deeplearning4j*. <https://web.archive.org/web/20201103204920/https://deeplearning4j.org/>, Accessed: 2020-11-08. 16
- [49] *Apache mxnet / a flexible and efficient library for deep learning*. <https://web.archive.org/web/20201108093437/https://mxnet.apache.org/versions/1.7.0/>, Accessed: 2020-11-10. 16